

Określenie optymalnej metody oceny stabilności próbek ropy naftowej z wykorzystaniem klasyfikacji

Mateusz Giedroyć
Filip Matusiak

June 2025

Contents

1	Opis problemu	2
1.1	Klasyfikacja	2
1.2	Rekomendacja metody	3
2	Klasyfikacja	3
2.1	Drzewo decyzyjne (Decision Tree)	3
2.2	Las losowy (Random Forest)	3
2.3	KNN (k-Nearest Neighbors)	4
2.4	Maszyna wektorów nośnych (SVM)	4
2.5	Sieć neuronowa (Neural Network)	4
2.6	Skuteczności klasyfikatorów	4
3	Wizualizacja	7
4	Ocena stabilności	10
4.1	Kryterium oceny stabilności	10
4.2	Wyniki metod oceny stabilności	11
5	Wnioski	13
6	Możliwe kierunki dalszych badań	14

Kod źródłowy i repozytorium

Pełny kod źródłowy oraz wyniki eksperymentów dostępne są w repozytorium GitHub: <https://github.com/giemat/PetroleumSamplesClassification>

1 Opis problemu

Celem projektu było wyznaczenia najbardziej optymalnej metody określania stabilności próbek ropy naftowej na podstawie ich charakterystyki. Aby tego dokonać, należało sklasyfikować próbki do próbek lekkich, średnich i ciężkich. A następnie, na podstawie klasyfikacji, określić skuteczność różnych metod oceny stabilności.

Opis cech chemicznych: Analizowane dane dotyczą właściwości fizyko-chemicznych próbek ropy naftowej. Zmienna **Density** oznacza gęstość, **S** zawartość związków nasyconych, **Ar** oznacza zawartość związków aromatycznych, **R** odnosi się do zawartości żywic, **As** to zawartość asfaltenów, a **CII** to wskaźnik indeksu niestabilności koloidalnej. Celem jest określenie klasy próbki (lekka, średnia, ciężka) na podstawie tych właściwości.

1.1 Klasyfikacja

Klasyfikacja została przeprowadzona różnymi metodami oraz dla różnych podzbiorów cech określających próbki (**Density**, **S**, **Ar**, **R**, **As**). Dane zawierały próbki przypisane do jednej z trzech klas. Należało zbadać, jak wybór różnych kombinacji cech wpływa na skuteczność klasyfikatorów oraz przedstawić wyniki wizualnie w postaci rzutów danych na przestrzeń dwuwymiarową. Metody klasyfikacji obejmowały:

- Drzewo decyzyjne (Decision Tree)
- Las losowy (Random Forest)
- KNN (k-Nearest Neighbors)
- Maszyna wektorów nośnych (SVM)
- Sieć neuronowa (Neural Network)

Do wizualizacji zastosowano metody redukcji wymiarowości w tym:

- PCA (Principal Component Analysis)
- LDA (Linear Discriminant Analysis)

- t-SNE (t-distributed Stochastic Neighbor Embedding)
- UMAP (Uniform Manifold Approximation and Projection)

1.2 Rekomendacja metody

Po sklasyfikowaniu próbek do klas przeprowadzona została ocena skuteczności każdej z metod oceny stabilności, w celu rekomendacji najbardziej optymalnej z nich. Metody oceny stabilności obejmowały:

- TSI (Turbiscan)
- CII (SARA)
- S-Value
- P-Value
- Y-Point Test

2 Klasyfikacja

2.1 Drzewo decyzyjne (Decision Tree)

Drzewa decyzyjne to klasyfikatory oparte na strukturze drzewiastej, w której każdy węzeł wewnętrzny reprezentuje test na jednej z cech, a każde rozgałęzienie odpowiada jednemu z możliwych wyników testu. Liście drzewa odpowiadają etykietom klas. Budowa drzewa opiera się zazwyczaj na kryterium optymalizacyjnym, takim jak indeks Giniego czy entropia informacyjna, które mierzą „czystość” zbiorów po podziale. Model ten jest łatwy do zinterpretowania, ale ma tendencję do nadmiernego dopasowania (overfitting), szczególnie przy głębokich drzewach.

2.2 Las losowy (Random Forest)

Random Forest to metoda zespołowa (ang. ensemble), która łączy wiele drzew decyzyjnych w celu poprawy dokładności predykcji i stabilności klasyfikatora. Każde drzewo uczone jest na losowej próbce danych (bootstrap), a podczas jego budowy wybierana jest losowa podgrupa cech do rozważenia przy każdym podziale. Wynik klasyfikacji to głosowanie większościowe spośród wszystkich drzew. Takie podejście zmniejsza wariancję i ogranicza ryzyko przeuczenia, kosztem zwiększonej złożoności obliczeniowej.

2.3 KNN (k-Nearest Neighbors)

KNN to leniwy (nieparametryczny) klasyfikator, który nie buduje jawnego modelu w fazie uczenia. Podczas klasyfikacji nowego punktu obliczana jest odległość (np. euklidesowa) do wszystkich punktów treningowych, a wynikowa etykieta przypisywana jest na podstawie większości klas wśród k najbliższych sąsiadów. Metoda ta jest prosta i skuteczna w przypadku danych dobrze rozdzielonych, ale bardzo wrażliwa na dobór metryki, wartość k oraz rozkład danych. Wymaga również dużo pamięci operacyjnej, ponieważ całość danych uczących musi być dostępna w fazie predykcji.

2.4 Maszyna wektorów nośnych (SVM)

SVM to klasyfikator maksymalizujący margines pomiędzy klasami. W wersji liniowej algorytm szuka hiperpłaszczyzny, która najlepiej oddziela dane należące do różnych klas. W wersji nieliniowej (z zastosowaniem jądra, np. RBF) możliwe jest odwzorowanie danych do przestrzeni cech o wyższym wymiarze, w której klasy są separowalne liniowo. Dzięki temu SVM jest bardzo skuteczny przy złożonych problemach, jednak wymaga dostrojenia parametrów (np. C , γ) i może być kosztowny obliczeniowo.

2.5 Sieć neuronowa (Neural Network)

Sieci neuronowe to modele inspirowane strukturą mózgu, składające się z warstw neuronów połączonych wagami. Każdy neuron przetwarza dane wejściowe, stosując funkcję aktywacji (np. ReLU, sigmoid), a wynik jest przekazywany do kolejnej warstwy. Sieci mogą mieć wiele warstw (głębokie sieci) i są zdolne do modelowania bardzo złożonych zależności. Uczenie polega na minimalizacji funkcji straty (np. krzyżowej entropii) przy użyciu algorytmu optymalizacji (np. Adam). Sieci neuronowe wymagają dużych zbiorów danych i mocy obliczeniowej, ale oferują wysoką elastyczność i skuteczność w wielu zadaniach klasyfikacyjnych.

2.6 Skuteczności klasyfikatorów

Skuteczność klasyfikatorów mierzona była za pomocą dokładności (accuracy), czyli stosunku poprawnie sklasyfikowanych próbek do ogólnej liczby próbek. W poniższej tabeli przedstawiono wyniki klasyfikacji dla różnych kombinacji cech i klasyfikatorów:

Analiza skuteczności klasyfikatorów

Features	DT	RF	KNN	SVM	NN	Average
Density	1.0	1.0	0.9	0.9	0.2	0.8
S	0.7	0.7	0.7	0.6	0.2	0.58
Ar	0.4	0.4	0.5	0.5	0.5	0.46
R	0.5	0.5	0.2	0.4	0.4	0.4
As	0.6	0.4	0.6	0.6	0.4	0.52
Density,S	0.7	0.6	0.3	0.4	0.6	0.52
Density,Ar	0.8	0.9	0.5	0.7	0.4	0.66
Density,R	1.0	0.9	0.2	0.4	0.6	0.62
Density,As	1.0	1.0	0.2	0.6	0.2	0.6
S,Ar	0.2	0.3	0.4	0.3	0.7	0.38
S,R	0.7	0.6	0.6	0.6	0.1	0.52
S,As	0.5	0.6	0.5	0.4	0.4	0.48
Ar,R	0.4	0.4	0.3	0.5	0.4	0.38
Ar,As	0.2	0.5	0.5	0.9	0.4	0.5
R,As	0.3	0.4	0.4	0.5	0.4	0.38
Density,S,Ar	1.0	1.0	0.6	0.3	0.4	0.66
Density,S,R	1.0	0.9	0.4	0.6	0.4	0.66
Density,S,As	1.0	1.0	0.7	0.4	0.2	0.66
Density,Ar,R	1.0	1.0	0.7	0.5	0.4	0.72
Density,Ar,As	0.9	1.0	0.3	0.4	0.5	0.62
Density,R,As	0.9	0.8	0.5	0.3	0.5	0.6
S,Ar,R	0.4	0.5	0.4	0.5	0.6	0.48
S,Ar,As	0.6	0.6	0.6	0.7	0.5	0.6
S,R,As	0.7	0.6	0.5	0.5	0.2	0.5
Ar,R,As	0.8	0.6	0.8	0.5	0.1	0.56
Density,S,Ar,R	0.8	0.8	0.3	0.5	0.1	0.5
Density,S,Ar,As	0.9	0.8	0.4	0.5	0.5	0.62
Density,S,R,As	1.0	0.9	0.7	0.6	0.4	0.72
Density,Ar,R,As	1.0	0.9	0.8	0.6	0.1	0.68
S,Ar,R,As	0.8	0.8	0.6	0.7	0.2	0.62
Density,S,Ar,R,As	1.0	1.0	0.4	0.6	0.2	0.64

Table 1: Zestawienie skuteczności klasyfikatorów dla różnych kombinacji cech

Na podstawie wyników klasyfikacji dla wszystkich możliwych kombinacji cech przeprowadzono analizę mającą na celu:

- określenie najlepszych podzbiorów cech pod względem średniej skuteczności

wynoszącej powyżej 70%,

- ocenę wpływu poszczególnych cech na skuteczność klasyfikacji,
- wyłonienie najlepszego klasyfikatora pod względem średniej skuteczności,
- wskazanie przypadków, dla których osiągnięto najwyższą dokładność ($\text{accuracy} = 1.0$).

Najlepsze kombinacje cech (Powyżej 70%)

- ('Density') – średnia skuteczność: 0,80
- ('Density', 'S', 'R', 'Ar') – średnia skuteczność: 0,72
- ('Density', 'Ar', 'R') – średnia skuteczność: 0,72

Wpływ poszczególnych cech na klasyfikację (średnia skuteczność gdy cecha występuje):

- Density—0,6438
- Ar—0,5837
- As—0,5737
- S—0,5713
- R—0,5662

Można zauważyć, że cecha **Density** miała największy pozytywny wpływ na skuteczność klasyfikacji.

Najlepszy klasyfikator (średnia dokładność):

- **Decision Tree** – średnia dokładność: 0,7355

Najwyższe osiągnięte dokładności ($\text{accuracy} = 1.0$):

Decision Tree

- Features: (Density), Accuracy: 1.0000
- Features: (Density, R), Accuracy: 1.0000
- Features: (Density, As), Accuracy: 1.0000
- Features: (Density, S, Ar), Accuracy: 1.0000

- Features: (Density, S, R), Accuracy: 1.0000
- Features: (Density, S, As), Accuracy: 1.0000
- Features: (Density, Ar, R), Accuracy: 1.0000
- Features: (Density, S, R, As), Accuracy: 1.0000
- Features: (Density, Ar, R, As), Accuracy: 1.0000
- Features: (Density, S, Ar, R, As), Accuracy: 1.0000

Random Forest

- Features: (Density), Accuracy: 1.0000
- Features: (Density, As), Accuracy: 1.0000
- Features: (Density, S, Ar), Accuracy: 1.0000
- Features: (Density, S, As), Accuracy: 1.0000
- Features: (Density, Ar, R), Accuracy: 1.0000
- Features: (Density, Ar, As), Accuracy: 1.0000
- Features: (Density, S, Ar, R, As), Accuracy: 1.0000

Uzyskane wyniki jednoznacznie wskazują, że najważniejszą cechą determinującą skuteczną klasyfikację jest **Density**, a klasyfikatory oparte na drzewach decyzyjnych osiągały najlepsze rezultaty dla złożonych podzbiorów zawierających tę cechę.

3 Wizualizacja

Aby umożliwić analizę danych w przestrzeni dwuwymiarowej, zastosowano techniki redukcji wymiarów opisane poniżej. Z podanych technik wybrano następnie najlepsze do przedstawienia separacji klas dla danego zbioru danych.

- **LDA (Linear Discriminant Analysis)** – nadzorowana metoda redukcji wymiarów maksymalizująca odległość między środkami klas, jednocześnie minimalizując wariancję wewnątrzklasową. Nadaje się do wizualizacji danych sklasyfikowanych. Osie LD1, LD2 oznaczają tzw.

liniowe dyskryminanty — czyli kierunki w przestrzeni cech, które najlepiej rozróżniają klasy.

LD1 (pierwsza liniowa dyskryminanta): reprezentuje kierunek maksymalnej separacji między klasami. Oś ta wyjaśnia największą wariancję w danych, która jest istotna dla rozróżniania klas.

LD2 (druga liniowa dyskryminanta): jest prostopadła do LD1 i odpowiada za drugi najważniejszy kierunek separacji. Wyjaśnia dodatkową wariancję, która również pomaga w odróżnieniu klas, ale w mniejszym stopniu niż LD1.

- **t-SNE (t-distributed Stochastic Neighbor Embedding)** — nieliniowa technika nienadzorowana, która odwzorowuje punkty w przestrzeni dwuwymiarowej, zachowując lokalne sąsiedztwa. Bardzo dobrze uwidacznia klastry, ale może przekłamywać globalną strukturę danych. Wymaga dostrojenia parametrów takich jak **perplexity** i liczba iteracji.
- **UMAP (Uniform Manifold Approximation and Projection)** — nowoczesna metoda redukcji wymiarów, która stara się zachować zarówno lokalną, jak i globalną strukturę danych. UMAP buduje graf sąsiedztwa danych i odwzorowuje go na przestrzeń niskowymiarową. W przeciwieństwie do t-SNE, skaluje się lepiej i umożliwia odtwarzalne wyniki (po ustawieniu ziarna losowości).
- **PCA (Principal Component Analysis)** — klasyczna metoda redukcji wymiarów, która znajduje kierunki maksymalnej wariancji w danych i odwzorowuje je na przestrzeń o mniejszej liczbie wymiarów. Jest to metoda liniowa, która dobrze działa przy danych o liniowej strukturze, ale może nie oddawać złożonych relacji w danych nieliniowych. Osie PC1 i PC2 w analizie PCA reprezentują główne kierunki zmienności danych w przestrzeni wielowymiarowej. PC1 (Pierwsza Składowa Główna) jest kierunkiem, który wyjaśnia największą możliwą wariancję w danych, podczas gdy PC2 (Druga Składowa Główna) wyjaśnia kolejną największą wariancję, przy czym jest ortogonalna do PC1.

Wizualizacje dla przykładowych kombinacji cech, dla których najlepiej widać separacje klas, przedstawiono poniżej:




Figure 1: Wizualizacja LDA dla Density, R, Ar, As




Figure 2: Wizualizacja PCA dla Density, As




Figure 3: Wizualizacja LDA dla Density, S, R

4 Ocena stabilności

4.1 Kryterium oceny stabilności

Kryterium oceny stabilności próbek ropy naftowej zostało użyte do sklasyfikowania stabilności próbek a następnie wynik został porównany z rzeczywistą stabilnością. Na tej podstawie wyznaczone zostały metody oceny stabilności, które najdokładniej przewidują stabilność próbek dla każdej z klas wyznaczonych metodą klasyfikacji. Stosując taki zabieg jesteśmy w stanie określić, która z metod oceny stabilności jest najbardziej optymalna dla danej klasy próbek ropy naftowej tym samym zmniejszając ryzyko błędnej klasyfikacji oraz koszty związane z przeprowadzaniem testów metodami o obniżonej skuteczności.

Liczbowe zakresy określenia stabilności próbki na podstawie wyniku eksperymentu zostały przedstawione w tabeli poniżej.

	INDEX STABILNOŚCI WEDŁUG METOD*				
	TURBISCAN	SARA	S-VALUE	P-VALUE	Testy bibułowe
	TSI	CII	S-VALUE	P-VALUE	Test punktowy
niestabilna	>2,5	>1,5	<1,5	<1,5	3
obniż. stab.	1,5-2,5	0,7-1,5	1,5-2,2	1,5-2	2
stabilna	<1,5	<0,7	>2,2	>2	1

Figure 4: Kryterium oceny stabilności

4.2 Wyniki metod oceny stabilności

Najczęściej wskazywane metody dla klas stabilności

Na podstawie różnych klasyfikatorów klas stabilności

- Predicted_Class_All
- Predicted_Class_Density
- Predicted_Class_Density_Ar_As
- Predicted_Class_Density_S_Ar_As

określono, która metoda pomiaru stabilności (spośród: TSI, CII, S-Value, P-Value, Y-Point Test) najczęściej była przypisywana do danej klasy jako najbardziej reprezentatywna.

Dla każdej klasy (lekka, średnia, ciężka) zliczono wystąpienia metod i wybrano tę, która miała najwięcej trafień.

Wyniki dla wszystkich trzech klasyfikatorów były spójne:

- Dla próbek lekkich (light) najczęściej przypisywana była metoda Y-Point
- Dla próbek średnich (medium) dominowała metoda P-Value
- Dla próbek ciężkich (heavy) również najczęściej występowała metoda P-Value
- Dla zbioru wszystkich próbek (ALL) najlepsza okazała się metoda P-Value

Zestawienie wyników oceny stabilności

	TSI [%]	CII [%]	S_VALUE [%]	P_VALUE [%]	Y_POINT [%]
Średnie	30	65	85	95	65
Cieężkie	57.14	76.19	90.48	100	42.86
Lekkie	70	50	60	50	90
Wszystkie	49.02	66.67	82.35	88.24	60.78

Table 2: Procentowa skuteczność oceny stabilności dla poszczególnych metod

Oznacza to, że niezależnie od zastosowanego podzbioru cech w klasyfikacji, metody **P-Value** oraz **Y-Point** okazały się najbardziej reprezentatywne dla odpowiednio średnich i ciężkich próbek (P-Value) oraz lekkich (Y-Point). Taki wynik świadczy o ich wysokiej spójności z rzeczywistą charakterystyką próbek w których metody te okazują się najlepsze.

Opis realizacji zadania

Zaimplementowano porównanie czterech klasyfikatorów na wszystkich możliwych kombinacjach od 1 do 5 cech. Dla każdej kombinacji:

- podzielono dane na zbiór treningowy i testowy,
- wytrenowano każdy z klasyfikatorów i obliczono dokładność predykcji,
- zapisano dokładności w postaci wykresów słupkowych,
- wykonano rzut danych na przestrzeń 2D za pomocą LDA, t-SNE oraz UMAP, PCA
- w przypadku kombinacji dwóch cech, wygenerowano wykres granicy decyzyjnej dla SVM.

Kod został modularnie podzielony: każdy klasyfikator zaimplementowany był w osobnym pliku, a funkcje pomocnicze i wizualizacje umieszczono w pliku `helper.py`.

Podejście oparte na analizie wszystkich podzbiorów cech umożliwiło zbadanie wpływu każdej cechy oraz ich kombinacji na skuteczność klasyfikacji. Wizualizacje pozwoliły na ocenę separowalności klas i działania klasyfikatorów.

5 Wnioski

Przeprowadzona analiza pozwoliła na określenie najbardziej optymalnych metod klasyfikacji oraz oceny stabilności próbek ropy naftowej. Na podstawie uzyskanych wyników można sformułować następujące wnioski:

- Spośród badanych cech największy wpływ na skuteczność klasyfikacji miała **Density**, co potwierdziło się we wszystkich najlepszych kombinacjach cech.
- Najwyższą średnią dokładność klasyfikacji osiągnął klasyfikator **Random Forest**, co wskazuje na jego wysoką skuteczność oraz odporność na przeuczenie, szczególnie w przypadku wielowymiarowych danych.
- Dokładność klasyfikatorów znacznie różniła się w zależności od użytego podzbioru cech, co podkreśla konieczność selekcji cech w problemach klasyfikacyjnych.
- Klasyfikatory oparte na drzewach (Decision Tree i Random Forest) wykazały najlepsze rezultaty w przypadkach, gdy cechy zawierały **Density**, osiągając nawet 100% dokładności ($\text{accuracy} = 1.0$) dla wybranych kombinacji.
- Wizualizacje danych za pomocą technik redukcji wymiarów (LDA, t-SNE, UMAP, PCA) umożliwiły lepsze zrozumienie rozkładu klas w przestrzeni cech oraz potwierdziły skuteczność klasyfikatorów w rozróżnianiu próbek.
- W ramach oceny stabilności próbek, możliwe było powiązanie wyników klasyfikacji z rzeczywistymi metodami pomiarowymi (TSI, CII, S-Value, P-Value, Y-Point Test). Pozwoliło to na identyfikację najbardziej niezawodnych metod oceny stabilności dla różnych klas próbek.
Takie podejście pozwala na redukcję kosztów i czasu w procesie badania próbek, poprzez wcześniejsze przypisanie próbki do klasy i wybór najbardziej adekwatnej metody stabilności na podstawie klasyfikacji.
- Ostatecznie, projekt pokazał, że wykorzystanie metod uczenia maszynowego może znacznie wspomóc analizę właściwości chemicznych i fizycznych surowców takich jak ropa naftowa, dostarczając praktycznych wskazówek dla przemysłu.
- W ramach oceny stabilności próbek, powiązano wyniki klasyfikacji z metodami eksperymentalnymi (TSI, CII, S-Value, P-Value, Y-Point Test). Analiza pokazała, że:

- Dla próbek średnich i ciężkich najczęściej identyfikowaną jako trafną była metoda **P-Value**,
- Dla próbek lekkich – metoda **Y-Point**.

Taka zgodność została potwierdzona niezależnie od zastosowanego modelu klasyfikacji klas stabilności. Świadczy to o przydatności tych metod jako referencyjnych w analizie stabilności oraz pozwala w przyszłości ograniczyć kosztowne badania tylko do najbardziej skutecznych procedur w zależności od rodzaju próbki.

6 Możliwe kierunki dalszych badań

- Zastosowanie bardziej zaawansowanych metod selekcji cech, takich jak RFE (Recursive Feature Elimination).
- Zbadanie wpływu rozszerzenia zbioru danych o dodatkowe cechy chemiczne.
- Porównanie klasyfikatorów z metodami nienadzorowanymi (np. clustering).